Projeto Livre: Visão Computacional com Transformers

Seleção e Detalhamento do Dataset

O domínio escolhido foi a Observação da Terra, utilizando o dataset **EuroSAT RGB**. Trata-se de um conjunto de dados multiclasse composto originalmente por 27.000 imagens de satélite divididas em 10 categorias de uso e cobertura do solo.

Justificativa de Redução da Amostra (50%): Para a execução deste projeto, o dataset foi intencionalmente reduzido para 50% do seu volume original. Esta decisão foi motivada pelas restrições de hardware do ambiente de desenvolvimento (Google Colab - Gratuito), que impõe limites baixos de memória RAM do sistema. Ao tentar carregar e processar o dataset completo, o ambiente sofria *crashes* recorrentes por *Out of Memory*. Como o escopo deste projeto acadêmico prioriza a implementação do pipeline e a análise do projeto, a amostragem de 50% garantiu a viabilidade computacional ponta a ponta sem comprometer o rigor da avaliação.

	Label ID	Label Nome	Quantidade	Proporção (%)
0	0	Annual Crop	1431	22.08
1	1	Forest	1416	21.85
2	2	Herbaceous Vegetation	1466	22.62
3	3	Highway	1193	18.41
4	4	Industrial Buildings	974	15.03

Justificativa Arquitetural: Por que o Vision Transformer (ViT)?

A arquitetura escolhida foi o **google/vit-base-patch16-224-in21k**. Para imagens de satélite, a escolha de um Transformer em vez de uma Rede Neural Convolucional (CNN) clássica baseia-se na forma como o modelo processa o contexto espacial.

Enquanto CNNs (como ResNet) possuem um viés indutivo focado em padrões locais (bordas e texturas próximas), o ViT divide a imagem em *patches* de 16x16 pixels e utiliza o mecanismo de *Self-Attention* global desde a primeira camada. Em imagens de satélite, o contexto global é crucial: uma rodovia (*Highway*) pode cruzar a imagem de ponta a ponta. O ViT consegue relacionar um *patch* no canto superior esquerdo com outro no canto inferior direito de forma muito mais eficiente, capturando as macroestruturas do terreno. O uso de *Transfer Learning* (pesos do ImageNet21k) permitiu que o modelo já iniciasse o treinamento

com uma excelente capacidade de extração de características básicas, necessitando apenas de ajuste no classificador final.

Estratégias de Gerenciamento de Memória

Para contornar as limitações de RAM descritas acima, técnicas estritas de gerenciamento de memória foram implementadas no código:

- **Coleta de Lixo (gc.collect()):** A chamada explícita ao *Garbage Collector* do Python foi utilizada para forçar a liberação imediata de memória de variáveis, tensores e arrays não mais referenciados. O Colab não libera a RAM instantaneamente quando uma variável sai de escopo; o gc.collect() mitiga picos de memória durante o carregamento de *batches* e plotagem de imagens.
- **Desativação Parcial do Attention (output_attentions=False):** Durante o treinamento, a geração dos mapas de atenção foi desligada. O cálculo e armazenamento das matrizes de atenção para cada imagem em cada época consome uma quantidade massiva de RAM e VRAM. O rastreamento foi ativado dinamicamente apenas na fase de inferência final, focando o recurso computacional onde ele era realmente necessário.
- **Limpeza do Dataset (remove_unused_columns=True):** Garantiu que as imagens brutas (objetos PIL) fossem descartadas da RAM do sistema assim que convertidas para os tensores alimentados na GPU.

Hiperparâmetros e Estratégia de Treinamento

Os hiperparâmetros foram ajustados para equilibrar o aprendizado rápido com a estabilidade do *fine-tuning*:

- **Learning Rate (5e-5):** Uma taxa de aprendizado baixa foi escolhida, pois taxas altas destruiriam os pesos pré-treinados do ImageNet21k. O objetivo foi apenas adaptar os extratores de características existentes ao novo domínio espacial.
- **Mixed Precision (fp16=True):** A utilização de precisão de 16-bits reduziu pela metade o consumo de memória de vídeo (VRAM) da GPU T4, acelerando o treinamento em cerca de 2x a 3x sem degradação perceptível nas métricas finais.
- **Weight Decay (0.01):** Aplicado como regularizador para evitar o overfitting. Como foi utilizado apenas metade do dataset original em uma rede com mais de 86 milhões de parâmetros, o risco de memorização dos dados de treino era alto.
- **Batch Size (16) e Dataloader Workers (0):** Configurou-se um lote conservador para não estourar a VRAM, e os *workers* em 0 para evitar que processos paralelos criassem cópias simultâneas do dataset na RAM do sistema.

Análise dos Resultados e Métricas

Os resultados da etapa de validação demonstram que o ViT atinge alta acurácia rapidamente devido à base do ImageNet21k. No entanto, a análise da Matriz de Confusão revela o comportamento não-linear do modelo ao lidar com classes de fronteira.

A arquitetura demonstra extrema confiança ao separar classes de texturas distintas (ex: *Forest* vs *Industrial*). As falhas (falsos positivos/negativos) tendem a se concentrar em classes com geometrias análogas como *Highway* (rodovias). Isso indica que o modelo confia fortemente na geometria linear contínua para estradas, e na distribuição de cores para vegetação. O erro não é aleatório, mas simétrico e explicável, o que valida a robustez do treinamento.

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score
1	No log	0.234905	0.940123	0.939673
2	0.236278	0.103027	0.973457	0.973371
3	0.107712	0.096770	0.974691	0.974632

```
--- Métricas da Época ---
Acurácia: 0.9401
F1-Score (Weighted): 0.9397
Matriz de Confusão:
[[339  12   6   1   2]
 [  0 371   0   0   0]
 [  2  20 310   0   1]
 [  8   6   5 260  33]
 [  0   0   1   0 243]]
--------------------------
```

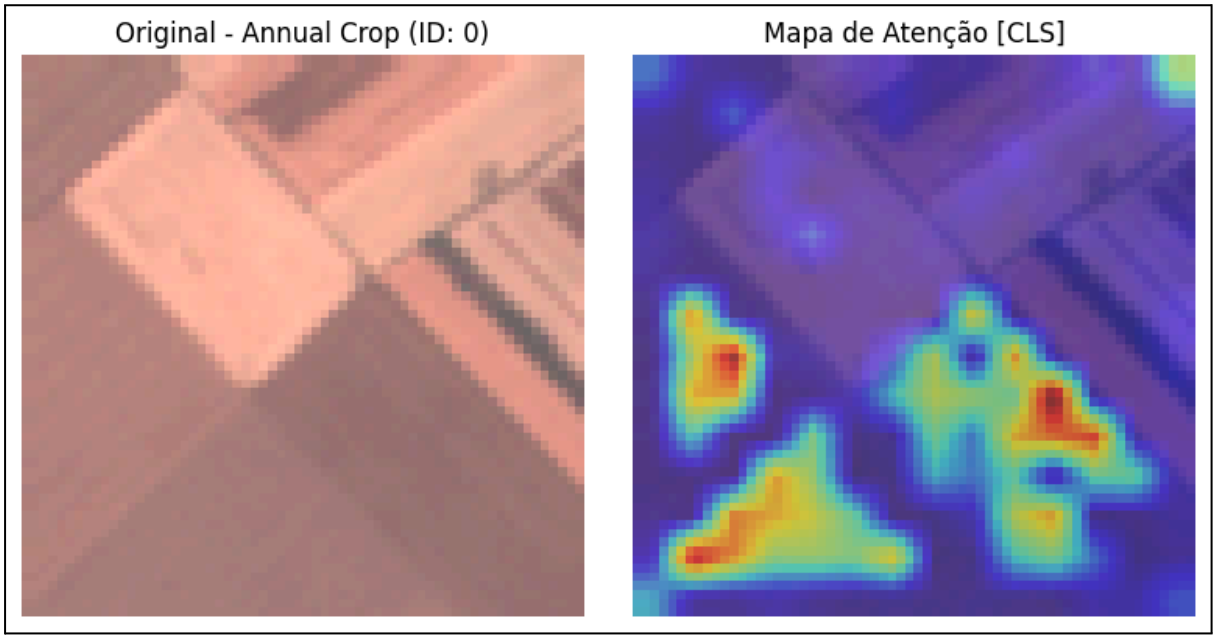
```
--- Métricas da Época ---
Acurácia: 0.9735
F1-Score (Weighted): 0.9734
Matriz de Confusão:
[[355   3   2   0   0]
 [  0 370   1   0   0]
 [  2   5 324   1   1]
 [  6   4   1 293   8]
 [  0   0   0   9 235]]
--------------------------
```

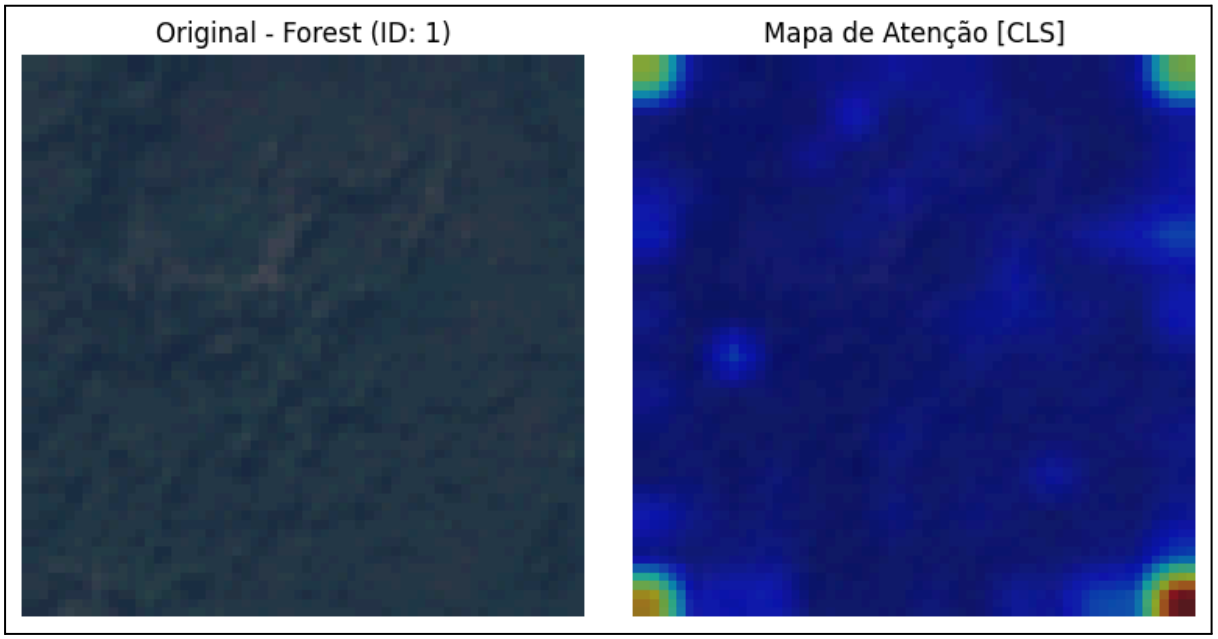
```
--- Métricas da Época ---
Acurácia: 0.9747
F1-Score (Weighted): 0.9746
Matriz de Confusão:
[[356   2   1   1   0]
 [  0 365   6   0   0]
 [  2   1 328   1   1]
 [  9   1   3 294   5]
 [  1   0   0   7 236]]
--------------------------
```

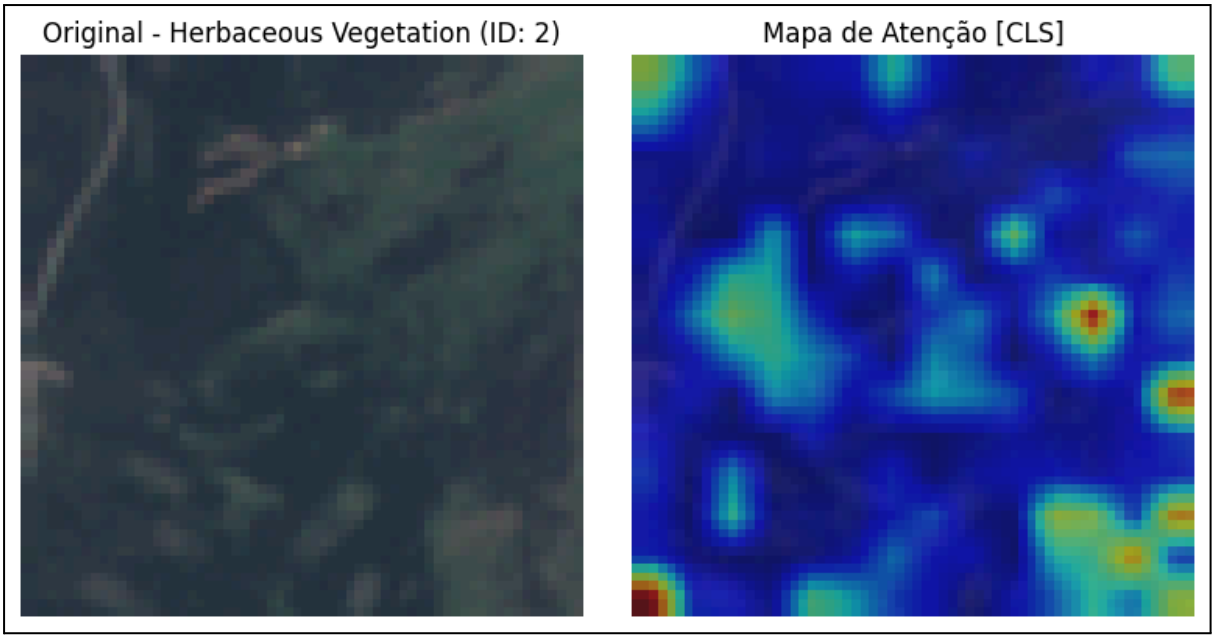
Interpretação dos Pesos de Atenção

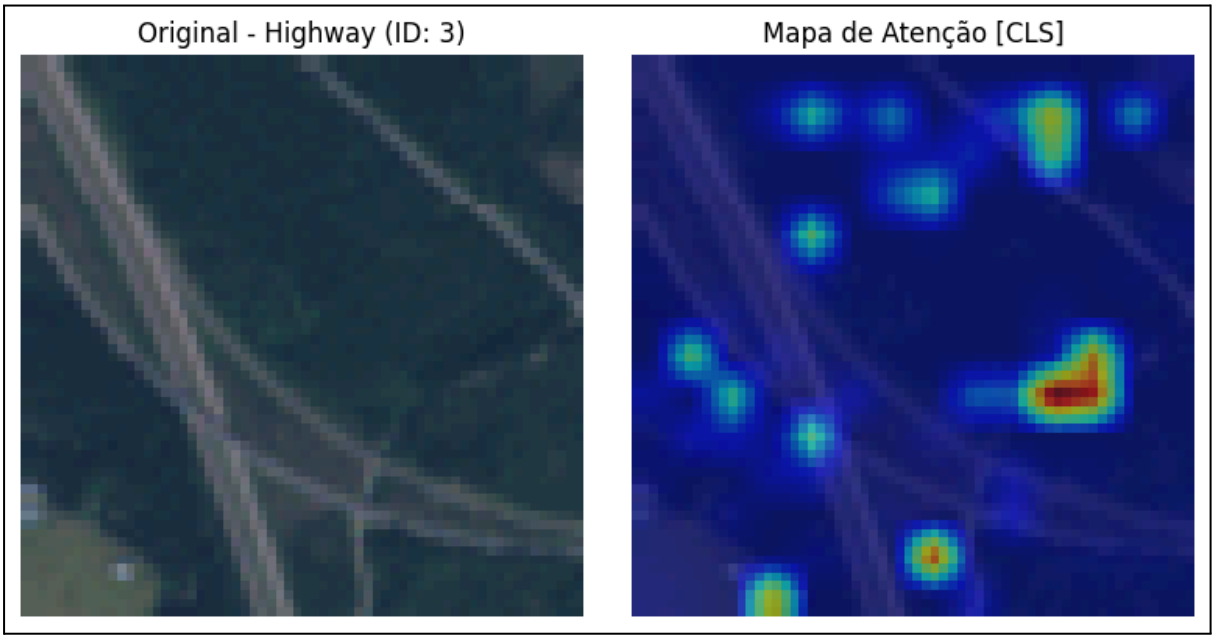
A extração do mapa de calor do último *Attention Head* evidencia visualmente a capacidade do modelo de distinguir a "fábrica de características" da imagem de satélite.

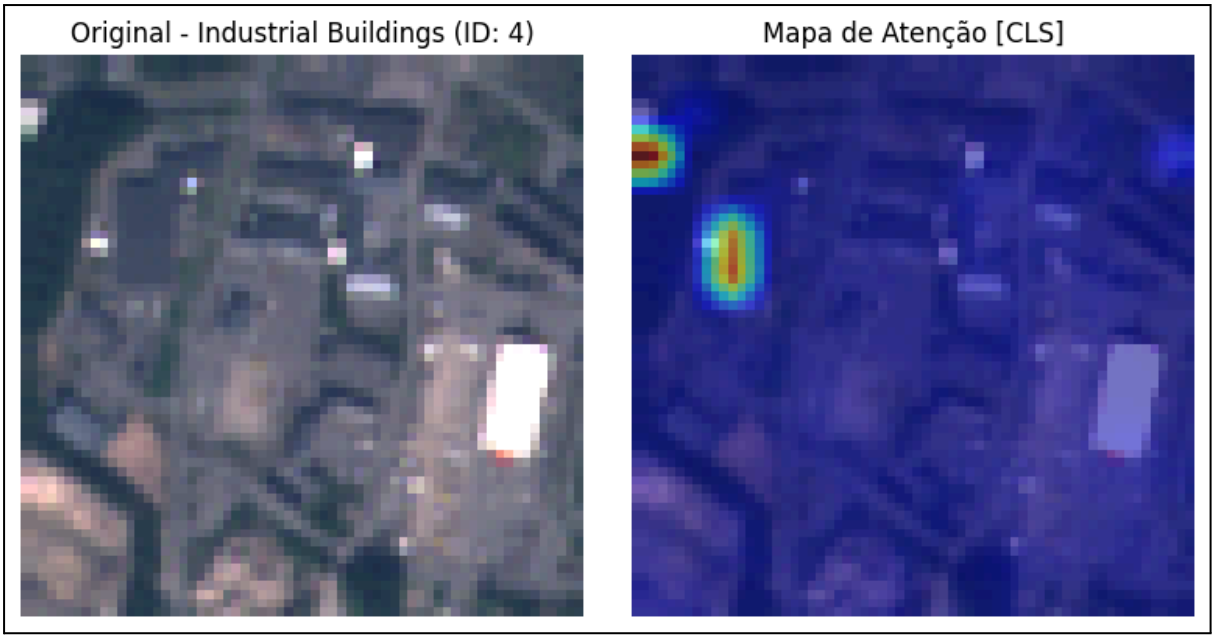
Ao sobrepor o mapa de atenção à imagem original, observa-se como o token especial de classificação pondera a importância espacial. Isso prova que o Vision Transformer não está decorando a luminosidade geral da imagem, mas sim aprendendo a focar a atenção do modelo nas geometrias estruturais que definem a classe. A arquitetura aprende de fato o "significado" semântico de uma rodovia versus uma floresta.






Original - Herbaceous Vegetation (ID: 2)
Mapa de Atenção [CLS]


Original - Highway (ID: 3)
Mapa de Atenção [CLS]



Trabalhos Futuros: O Que Eu Mudaria

Embora a solução implementada atende rigorosamente aos requisitos do problema, iterações futuras para o ambiente de produção envolveriam:

1. **Migração de Infraestrutura e Dataset Completo:** Executar o treinamento com 100% dos dados em um ambiente em nuvem com GPUs dedicadas para maximizar a generalização.
2. **Modelos de Domínio Específico:** Substituir o modelo pré-treinado no ImageNet (imagens cotidianas) por versões do ViT pré-treinadas especificamente em dados orbitais, como modelos da fundação SatMAE ou equivalentes. Os extratores de bordas já estariam otimizados para topografia.
3. **Data Augmentation Agressivo:** Implementar rotações aleatórias completas (360º) e variações de cor/brilho. Diferente de fotos comuns, uma imagem de satélite não tem "cima" ou "baixo", e as estações do ano alteram drasticamente a cor da vegetação (um fator que o modelo precisa aprender a ignorar).

Reconhecimento Semântico em Publicidade Visual com CLIP

Para a realização do experimento, foram selecionadas 500 imagens do ADS-16, buscando contemplar a diversidade de anúncios presentes no conjunto de dados. Essa amostra foi utilizada para extrair os embeddings das imagens com o modelo CLIP e calcular a similaridade de cosseno em relação a 20 descrições textuais. Foi definido um threshold de 0,24 para contabilizar a presença semântica de cada categoria, considerando as imagens que apresentaram similaridade superior a esse valor. A partir dessas ocorrências, foi elaborado um ranking das categorias mais frequentemente identificadas.

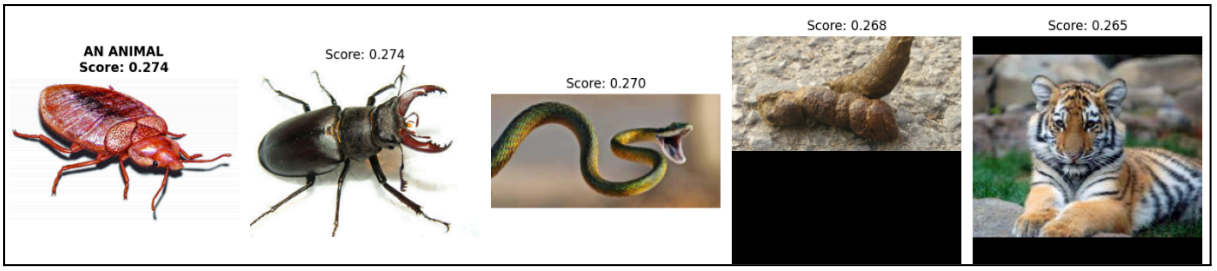
Análise das categorias e dos scores

Os resultados apontaram *food product* como a categoria mais frequente, com 41 ocorrências, seguida por *an animal*, com 36. Na sequência, destacaram-se *outdoor scenery*, *sports equipment* e *cosmetics*, demonstrando maior associação semântica dessas categorias com as imagens analisadas. Entre as demais categorias, *a toy* apresentou o maior score médio, de 0,2015, seguido por *an animal*, com 0,2014, e *food product*, com 0,1982. Por outro lado, *a building* apresentou o menor score médio entre os valores informados, com 0,1724. A categoria *a bottle* não registrou ocorrências acima do threshold, embora tenha apresentado score médio de 0,1840. Esses resultados demonstram que a frequência de ocorrência e a similaridade média representam métricas distintas: uma categoria pode apresentar maior frequência sem necessariamente possuir o maior score médio. As categorias menos frequentes podem estar presentes em parte da amostra, mas não atingir o limiar definido com a mesma regularidade.

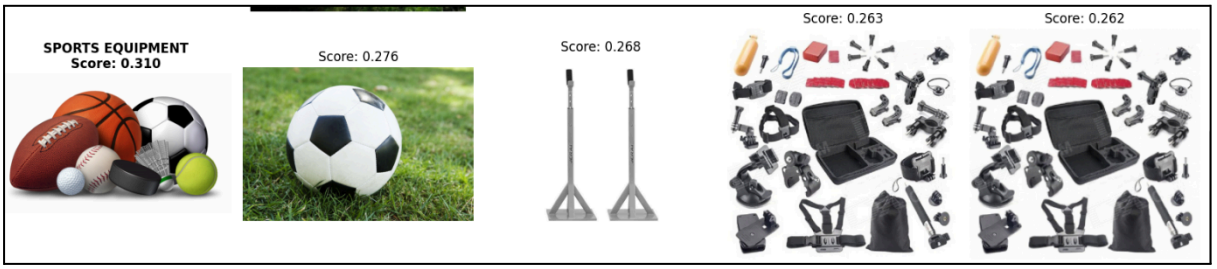
Exemplos visuais das cinco categorias mais frequentes

Para validar qualitativamente o ranking, foram selecionadas imagens representativas das cinco categorias com maior frequência: *food product*, *an animal*, *outdoor scenery*, *sports equipment* e *cosmetics*. A inspeção visual permite comparar as correspondências encontradas pelo CLIP com o conteúdo efetivo dos anúncios, identificando resultados coerentes e possíveis associações equivocadas.









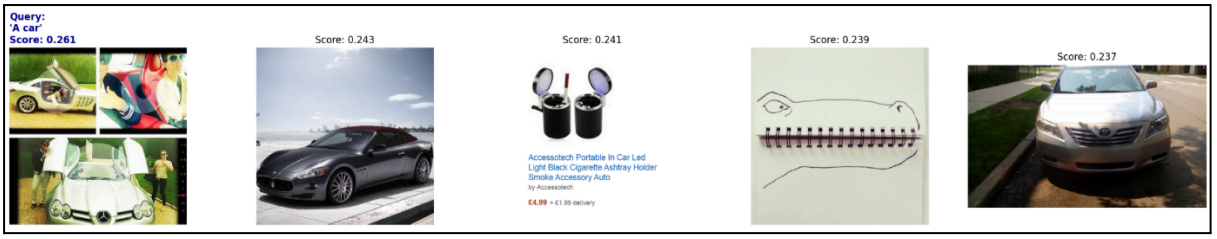


Busca semântica por consulta textual

Foram executadas oito consultas textuais para avaliar a recuperação de imagens por similaridade semântica. Os resultados das consultas são apresentados a seguir, acompanhados de espaço para inclusão das imagens mais relevantes e análise da correspondência entre as descrições e o conteúdo recuperado.

Consulta 1 — A car

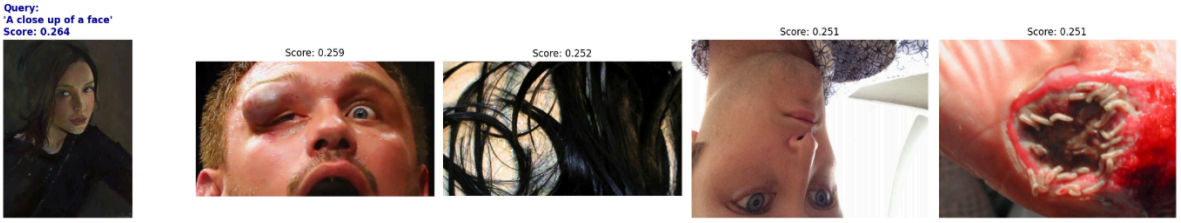
A consulta foi utilizada para verificar a recuperação de anúncios que apresentam automóveis. A análise das cinco imagens mais similares permite avaliar se o CLIP identifica veículos como elementos centrais ou secundários da composição publicitária.



Análise: O CLIP identificou corretamente três carros e a palavra *car* no anúncio, porém ele identificou de forma errada um desenho que lembra um pouco o formato da frente de um carro de forma errada.

Consulta 2 — A close up of a face

Essa consulta permite avaliar a recuperação de imagens com rostos em primeiro plano, observando se o modelo considera adequadamente o enquadramento solicitado.



Análise: Ele identificou muito bem algumas imagens, porém confundiu cabelo e um ferimento com faces.

Consulta 3 — A red dress

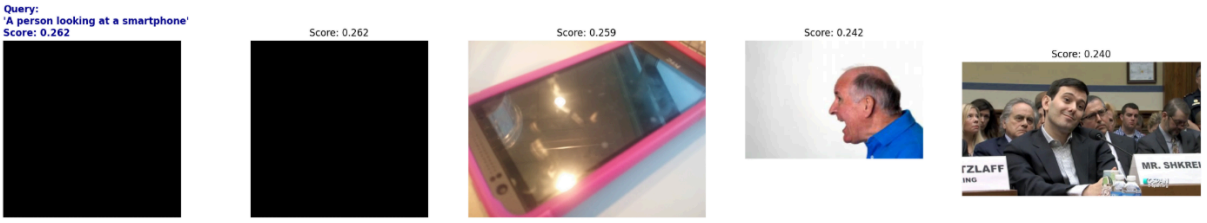
A consulta avalia a capacidade do modelo de associar uma peça de vestuário a uma característica específica de cor, verificando se as imagens recuperadas apresentam vestidos vermelhos.



Análise: Ele identificou muito bem a palavra *dress* e a palavra *red* nas imagens, porém não achou nenhuma amostra de um vestido vermelho em si.

Consulta 4 — A person looking at a smartphone

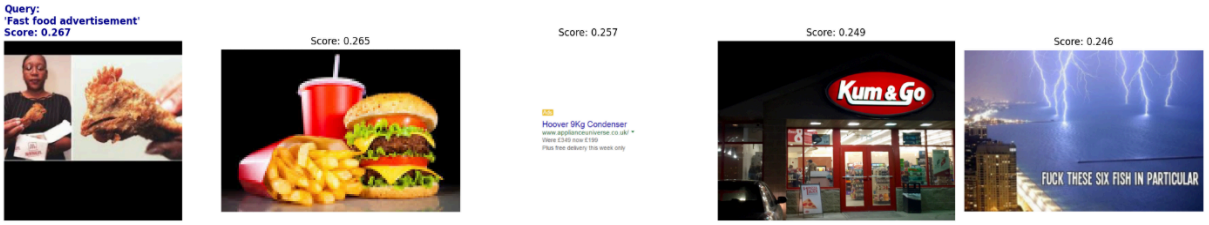
Essa consulta investiga se o CLIP consegue recuperar imagens que relacionam uma pessoa a um smartphone em uma situação específica, em vez de identificar apenas um dos elementos isoladamente.



Análise: Nessa consulta não foi identificado nenhuma imagem nesta situação específica. Ele entendeu dois quadrados pretos como se fosse a tela de um smartphone de forma errada.

Consulta 5 — Fast food advertisement

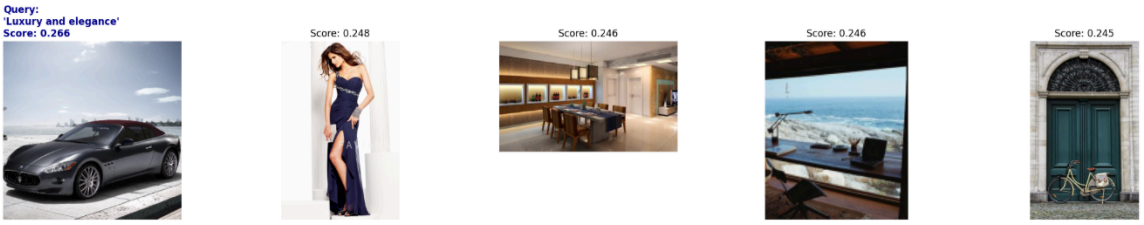
A consulta busca anúncios relacionados a alimentos de consumo rápido. Os resultados permitem avaliar se o modelo recupera imagens compatíveis com o produto e o contexto publicitário solicitado.



Análise: O CLIP identificou muito bem os anúncios de *fast food*, exceto na última imagem onde a simples presença da palavra *fish* o fez classificar como um *fast food advertisement*.

Consulta 6 — Luxury and elegance

Essa consulta avalia a recuperação de imagens associadas a luxo e elegância, considerando se os elementos visuais e os produtos apresentados são coerentes com esses conceitos.



Análise: Nesta consulta, foi associado muito bem, cinco diferentes tipos de imagens que estão relacionadas a *luxury and elegance*.

Consulta 7 — Speed and performance

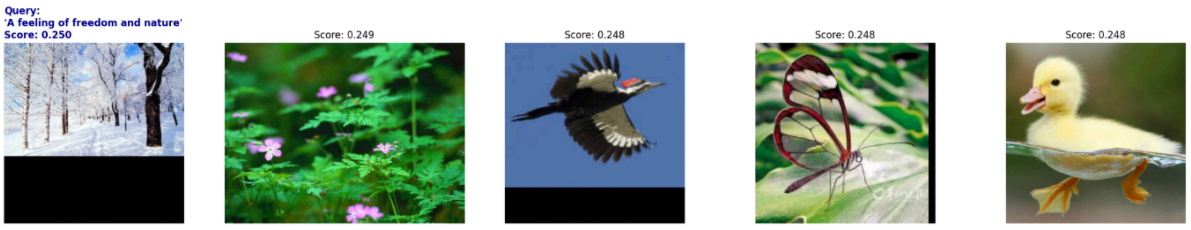
A consulta investiga a associação entre imagens publicitárias e conceitos de velocidade e desempenho, observando se os resultados apresentam elementos visuais compatíveis com essas ideias.



Análise: Esta consulta revela que o CLIP associou tanto imagens de carro como uma imagem de esporte para *speed and performance*, o que faz sentido considerando performance esportiva.

Consulta 8 — A feeling of freedom and nature

Essa consulta avalia a recuperação de imagens relacionadas à natureza e à sensação de liberdade, verificando se as paisagens e os demais elementos visuais correspondem à intenção da busca.



Análise: Nesta consulta, obtivemos os melhores resultados, pois mostra tanto paisagens como animais livres na natureza que indica claramente a *feeling of freedom and nature*.

Classificador com CNN Pré-treinada

Foi utilizada uma CNN pré-treinada com aproximadamente 23,5 milhões de parâmetros totais. O backbone foi congelado, permitindo que o treinamento se concentrasse exclusivamente na nova camada de classificação, adaptada às sete classes do problema.

Apenas 14.343 parâmetros foram treinados, o que representa aproximadamente 0,061% do total de parâmetros. Essa estratégia reduz o custo computacional e aproveita as características visuais aprendidas previamente pelo modelo.

Resultados do treinamento

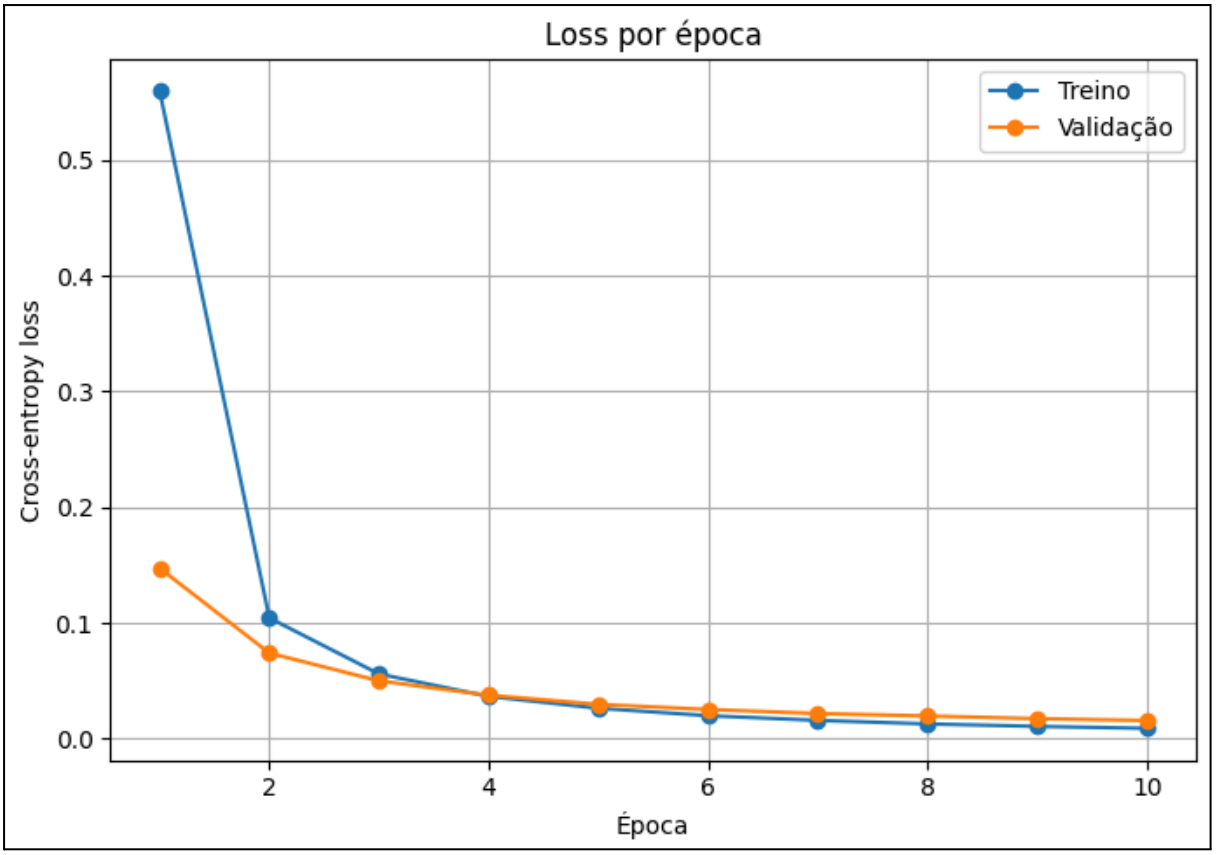
Durante as dez épocas, observou-se uma redução contínua das funções de perda (*loss*) de treinamento e validação.

A *train loss* caiu de 0,5599 para 0,0090, enquanto a *val loss* diminuiu de 0,1475 para 0,0158. Simultaneamente, a acurácia de treinamento evoluiu de 92,00% para 100%, e a acurácia de validação permaneceu em 100% desde a primeira época.

Esses resultados indicam que o modelo aprendeu a distinguir as classes presentes nos dados utilizados no experimento. A queda da perda de validação, mesmo com a acurácia já em 100%, indica que as previsões corretas se tornaram progressivamente mais confiantes.

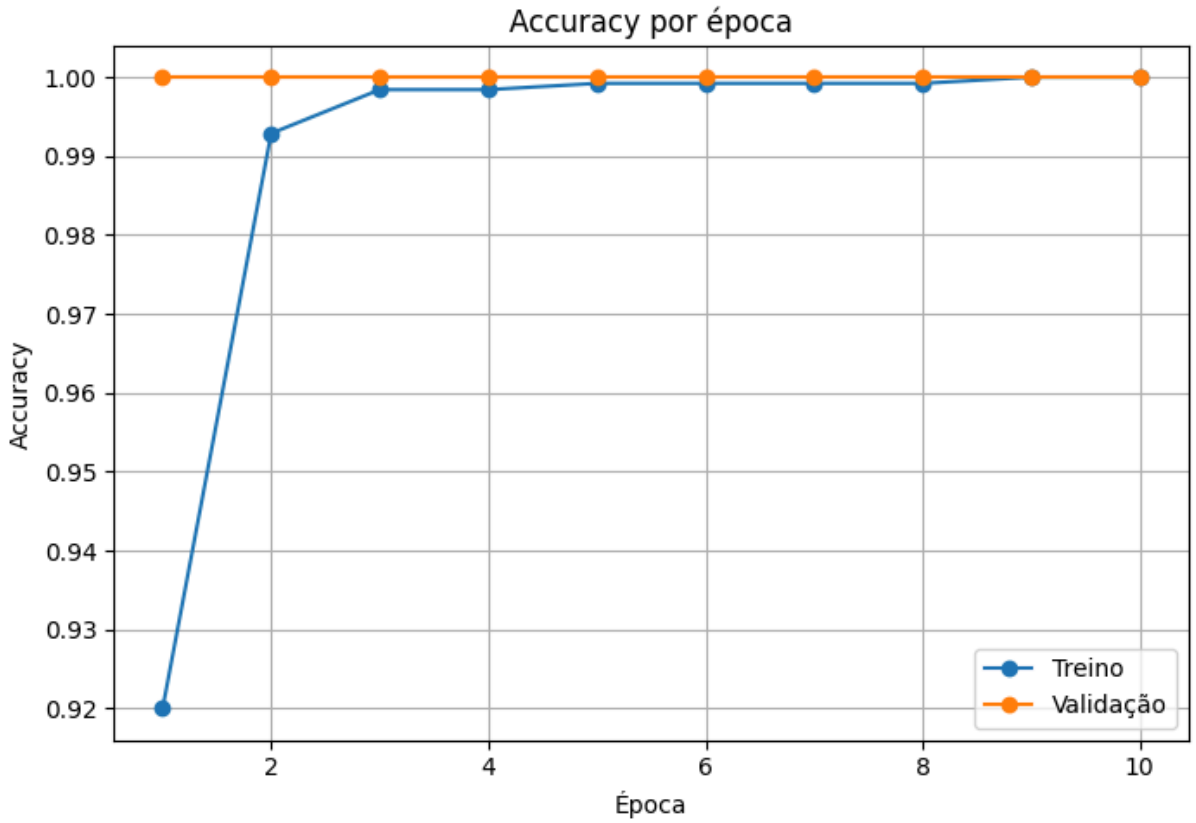
Entretanto, a acurácia perfeita na validação desde a primeira época é um resultado que merece investigação adicional, especialmente considerando o tamanho relativamente reduzido do dataset.

Curva de Loss por época



As duas curvas apresentam tendência de queda ao longo do treinamento. A redução da perda de validação sugere melhoria na confiança das previsões sobre esse conjunto. Não há aumento da perda de validação que indique um sinal clássico de sobreajuste, embora isso, isoladamente, não descarte outros problemas de generalização.

Curva de Accuracy por época



A acurácia de treinamento aumentou rapidamente até alcançar 100% na nona época. A acurácia de validação permaneceu em 100% durante todas as épocas registradas. Esse comportamento indica excelente desempenho nos dados avaliados.

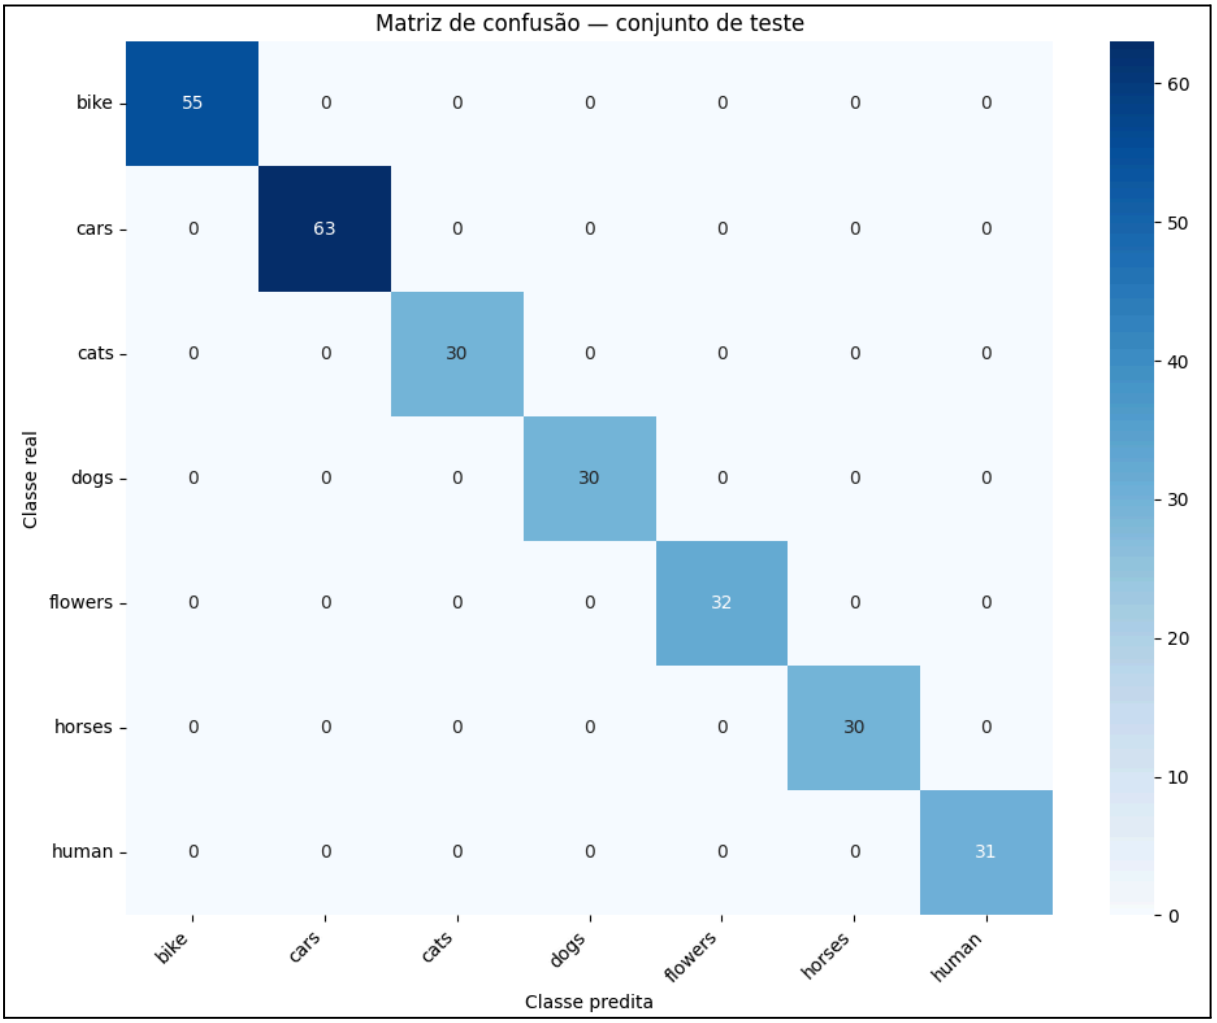
Avaliação no conjunto de teste

O modelo obteve **100% de acurácia global no conjunto de teste**, acertando todas as 271 imagens avaliadas.

As métricas de precisão (*precision*), revocação (*recall*) e F1-score também foram de 100% para todas as classes.

Relatório por classe:

	precision	recall	f1-score	support
bike	1.0000	1.0000	1.0000	55
cars	1.0000	1.0000	1.0000	63
cats	1.0000	1.0000	1.0000	30
dogs	1.0000	1.0000	1.0000	30
flowers	1.0000	1.0000	1.0000	32
horses	1.0000	1.0000	1.0000	30
human	1.0000	1.0000	1.0000	31
accuracy			1.0000	271
macro avg	1.0000	1.0000	1.0000	271
weighted avg	1.0000	1.0000	1.0000	271



Análise e propostas de melhoria

Apesar dos excelentes resultados, adotaria algumas melhorias para avaliar a robustez do classificador e sua capacidade de generalização. Os experimentos seriam realizados individualmente, mantendo uma configuração de referência para permitir comparações justas.

Geometric augmentation

Utilizaria flip horizontal, pequenas rotações e recortes aleatórios durante o treinamento. Essas transformações aumentam a diversidade visual dos exemplos e ajudam a reduzir a dependência de posições e enquadramentos específicos.

O flip horizontal é especialmente apropriado para objetos como bicicletas, carros e animais, desde que a transformação não altere o significado da classe. As rotações devem ser moderadas para evitar imagens pouco realistas.

Scale variation

Utilizaria *RandomResizedCrop* para variar o enquadramento e a escala dos objetos, seguido do redimensionamento para a dimensão de entrada exigida pelo backbone.

Essa estratégia pode melhorar a capacidade do modelo de reconhecer objetos que aparecem em diferentes tamanhos e distâncias. É importante, contudo, preservar uma parte suficiente do objeto para não eliminar características relevantes durante os recortes.

Estudo de caso 1 - Detecção de COVID-19 em Radiografias de Tórax

O dataset possui 1.200 radiografias distribuídas em três classes. A classe COVID-19 representa apenas 10% do conjunto de dados. Isso cria um problema relevante para o treinamento de um classificador médico: o modelo pode aprender a favorecer as classes majoritárias e ainda apresentar uma accuracy aparentemente elevada.

Problemas técnicos e impactos clínicos

Desbalanceamento das classes

A classe COVID-19 contém apenas 120 imagens, contra 840 imagens normais. O modelo pode privilegiar a classe majoritária e apresentar baixo recall para COVID-19.

Divisão sem estratificação

A divisão 80/20 sem estratificação pode produzir proporções diferentes de cada classe entre treino e validação. Com apenas 120 imagens de COVID-19, essa variação é importante.

ResNet-18 treinada do zero

Uma rede com muitos parâmetros treinada com poucas imagens pode não aprender características generalizáveis, especialmente na classe minoritária.

Avaliação somente por accuracy

A accuracy global não informa quantos pacientes com COVID-19 foram classificados incorretamente.

Os 93% de accuracy no treino e 61% na validação também sugerem uma diferença importante de generalização. Entretanto, esses valores isoladamente não comprovam overfitting nem revelam o recall de COVID-19: para isso, precisamos examinar as métricas por classe e a matriz de confusão.

Abordagem generativa escolhida: GAN condicional (cGAN)

A técnica escolhida será uma Conditional Generative Adversarial Network (cGAN), que aprende a gerar imagens condicionadas à classe informada. Neste experimento, o objetivo é gerar novas radiografias sintéticas da classe COVID-19 para ampliar sua representação durante o treinamento do classificador.

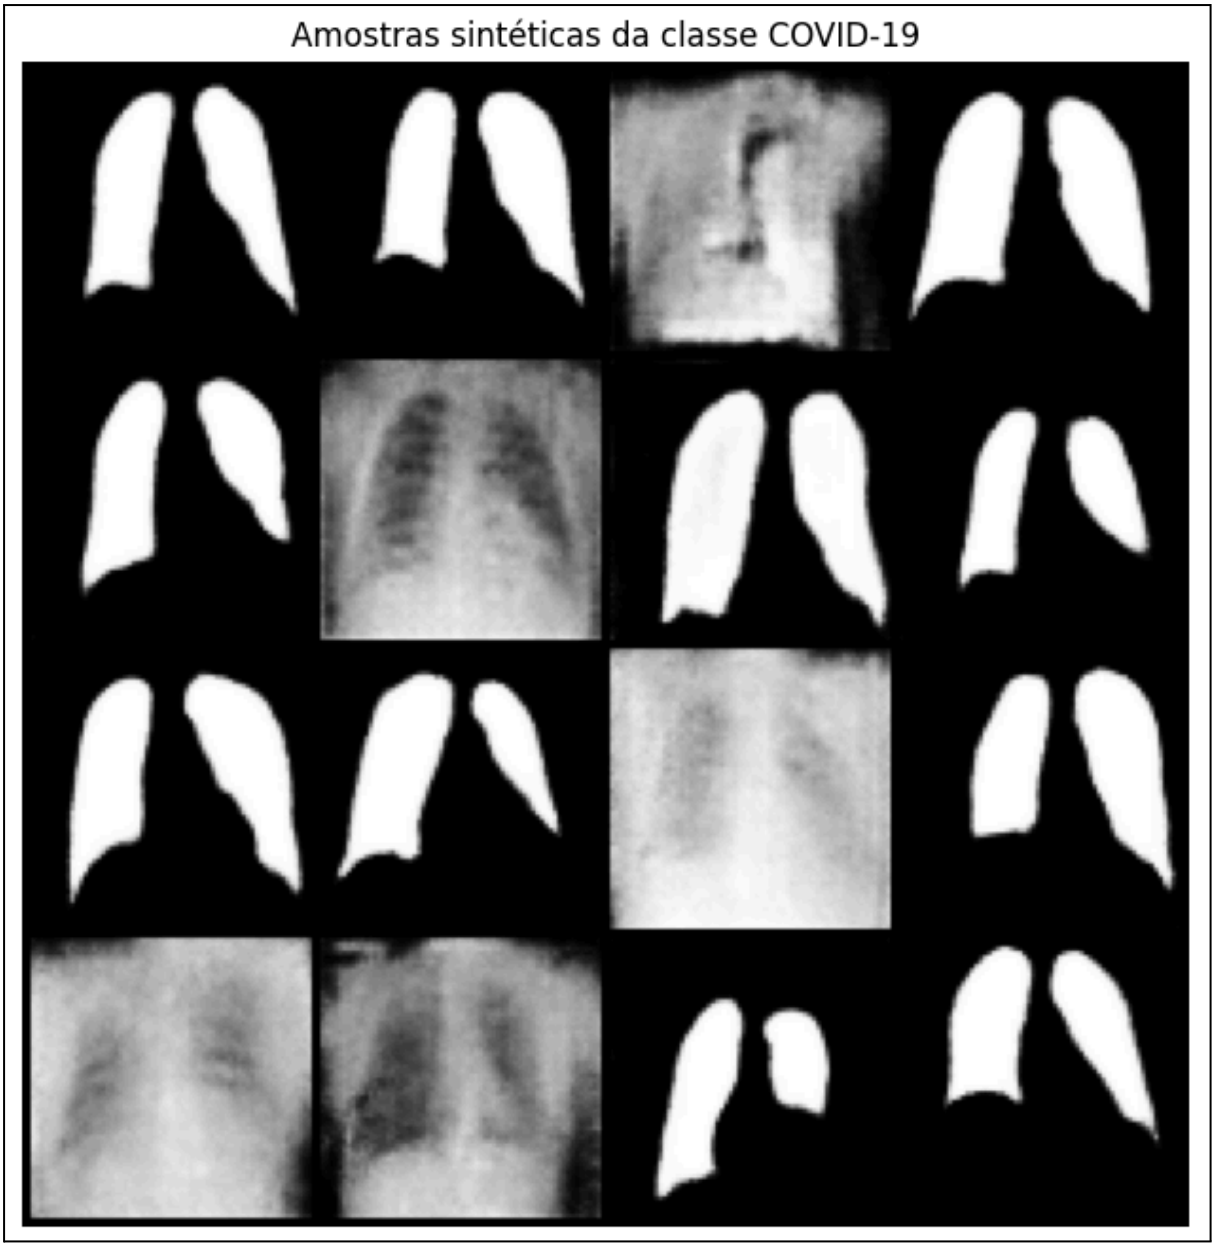
Por que não utilizar CycleGAN?

A CycleGAN é especialmente útil quando se deseja traduzir imagens entre dois domínios, como radiografias de diferentes equipamentos ou instituições. Neste estudo, o problema prioritário é a escassez de uma classe específica, portanto a cGAN é uma escolha mais direta.

Análise e conclusão

O estudo de caso investigou a utilização de redes generativas para ampliar a representação da classe COVID-19 em um sistema de classificação de radiografias de tórax. Em vez de utilizar exclusivamente o conjunto de 1.200 imagens descrito no enunciado, foi adotado o COVID-19 Radiography Database, disponível publicamente no Kaggle, que possibilitou trabalhar com um conjunto de maior dimensão e quatro classes: COVID, Lung_Opacity, Normal e Viral Pneumonia.

A GAN condicional foi treinada durante 30 épocas e utilizada para gerar 660 imagens sintéticas de COVID-19. Essas imagens foram incorporadas ao conjunto de treinamento de uma ResNet-18 pré-treinada, permitindo comparar dois cenários: treinamento com imagens reais e treinamento com imagens reais acrescidas de imagens sintéticas.

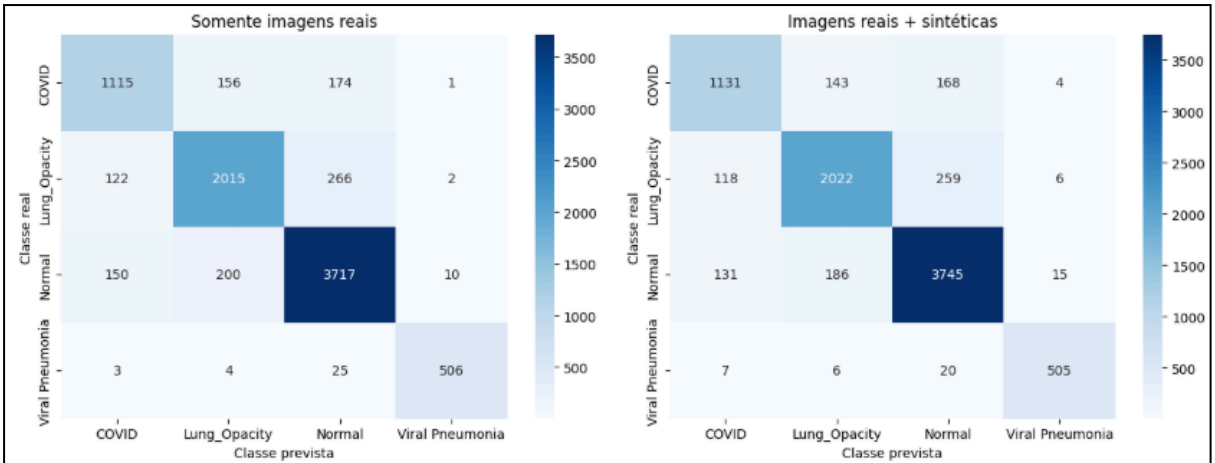


Os resultados demonstraram uma melhora nas métricas avaliadas. O recall de COVID-19 aumentou de 77,11% para 78,22%, uma variação de 1,11 ponto percentual. A precision passou de 80,22% para 81,54%, o F1-score aumentou de 78,63% para 79,84% e a accuracy global evoluiu de 86,85% para 87,44%. O recall macro também apresentou melhora, passando de 86,53% para 87,00%.

```
Época 1/8 | Loss: 0.5236 | Val accuracy: 0.8440 | Val recall COVID: 0.6957
Época 2/8 | Loss: 0.4059 | Val accuracy: 0.8525 | Val recall COVID: 0.7026
Época 3/8 | Loss: 0.3682 | Val accuracy: 0.8528 | Val recall COVID: 0.7531
Época 4/8 | Loss: 0.3382 | Val accuracy: 0.8545 | Val recall COVID: 0.7490
Época 5/8 | Loss: 0.3193 | Val accuracy: 0.8577 | Val recall COVID: 0.7130
Época 6/8 | Loss: 0.2902 | Val accuracy: 0.8555 | Val recall COVID: 0.7448
Época 7/8 | Loss: 0.2345 | Val accuracy: 0.8623 | Val recall COVID: 0.7766
Época 8/8 | Loss: 0.2089 | Val accuracy: 0.8672 | Val recall COVID: 0.7704
Época 1/8 | Loss: 0.5091 | Val accuracy: 0.8267 | Val recall COVID: 0.7102
Época 2/8 | Loss: 0.3938 | Val accuracy: 0.8365 | Val recall COVID: 0.6542
Época 3/8 | Loss: 0.3616 | Val accuracy: 0.8490 | Val recall COVID: 0.6667
Época 4/8 | Loss: 0.3314 | Val accuracy: 0.8409 | Val recall COVID: 0.5781
Época 5/8 | Loss: 0.2817 | Val accuracy: 0.8684 | Val recall COVID: 0.7690
Época 6/8 | Loss: 0.2521 | Val accuracy: 0.8672 | Val recall COVID: 0.7642
Época 7/8 | Loss: 0.2275 | Val accuracy: 0.8669 | Val recall COVID: 0.7739
Época 8/8 | Loss: 0.2080 | Val accuracy: 0.8642 | Val recall COVID: 0.6929
```

	Modelo	Accuracy	Recall COVID-19	Precision COVID-19	F1 COVID-19	Recall macro
0	Somente imagens reais	0.8685	0.7711	0.8022	0.7863	0.8653
1	Imagens reais + sintéticas	0.8744	0.7822	0.8154	0.7984	0.8700

```
Variação absoluta do recall COVID-19: +0.0111
Variação em pontos percentuais: +1.11 p.p.
```




```
=== Somente imagens reais ===
                precision    recall  f1-score   support

         COVID       0.80      0.77      0.79      1446
   Lung_Opacity      0.85      0.84      0.84      2405
        Normal       0.89      0.91      0.90      4077
Viral Pneumonia      0.97      0.94      0.96       538

      accuracy                           0.87      8466
     macro avg       0.88      0.87      0.87      8466
  weighted avg       0.87      0.87      0.87      8466

=== Imagens reais + sintéticas ===
                precision    recall  f1-score   support

         COVID       0.82      0.78      0.80      1446
   Lung_Opacity      0.86      0.84      0.85      2405
        Normal       0.89      0.92      0.91      4077
Viral Pneumonia      0.95      0.94      0.95       538

      accuracy                           0.87      8466
     macro avg       0.88      0.87      0.87      8466
```

Esses resultados indicam que a inclusão de imagens sintéticas esteve associada a uma melhoria modesta no desempenho do classificador, particularmente na identificação de casos positivos de COVID-19. Entretanto, não é possível concluir que a GAN foi responsável por todo o ganho observado sem experimentos repetidos, análise estatística e avaliação da qualidade das imagens geradas.

O trabalho também evidencia que a accuracy isolada é insuficiente para avaliar sistemas de triagem médica. O recall da classe positiva e a análise dos falsos negativos são fundamentais para compreender os riscos de classificação incorreta. Como melhorias futuras, recomenda-se comparar a augmentation generativa com técnicas tradicionais, executar experimentos com múltiplas sementes, estimar intervalos de confiança, verificar possíveis vazamentos por paciente e realizar validação externa.

Por fim, o sistema desenvolvido deve ser considerado um experimento acadêmico, sem finalidade de diagnóstico clínico. A utilização de imagens sintéticas não garante maior segurança ou generalização, sendo necessária uma validação rigorosa antes de qualquer aplicação médica.

Estudo de caso 2 - Transfer Learning para Análise de Tráfego Urbano

Análise do problema

O sistema apresenta uma accuracy de 78% na validação, mas as falhas observadas em produção indicam que o desempenho medido durante o desenvolvimento não representa adequadamente as condições reais de operação. O problema não está necessariamente na arquitetura ResNet-50, mas na combinação entre a quantidade e a diversidade dos dados, a estratégia de validação e a capacidade de generalização do modelo.

Problemas identificados

Quantidade insuficiente e baixa diversidade dos dados

O treinamento utilizou apenas 800 frames de 12 câmeras, o que pode ser insuficiente para representar a diversidade de condições encontradas no trânsito urbano. Além disso, imagens consecutivas de uma mesma câmera podem apresentar características muito semelhantes, reduzindo a diversidade efetiva do conjunto de treinamento.

Impacto operacional: o modelo pode memorizar características específicas das câmeras e apresentar bom desempenho nas imagens conhecidas, mas falhar diante de cenários diferentes, como novas vias, condições climáticas ou variações de iluminação.

Abordagem proposta: ampliar a base de dados com imagens de diferentes câmeras, horários, condições meteorológicas e níveis de tráfego. Também buscaria equilibrar a quantidade de exemplos das três classes e verificar se cada categoria está adequadamente representada nas diferentes condições de captura.

Estratégia de validação inadequada

A accuracy de 78% não é suficiente para comprovar que o modelo generaliza bem. Caso frames da mesma câmera ou de períodos muito próximos tenham sido distribuídos entre treinamento e validação, os resultados podem estar superestimados devido à semelhança entre as imagens.

Impacto operacional: o sistema pode ser implantado acreditando-se que possui desempenho satisfatório, embora apresente erros frequentes em câmeras ou ambientes que não foram adequadamente representados na validação.

Abordagem proposta: utilizar uma validação separada por câmera, mantendo câmeras inteiras fora do treinamento para avaliar a capacidade de generalização espacial. Também

realizaria testes temporais, com dados de períodos posteriores, e avaliaria métricas como precisão, recall e F1-score por classe, além da matriz de confusão.

Ausência de representatividade de condições climáticas e períodos noturnos

As falhas em situações de chuva e durante a noite demonstram que o modelo não aprendeu representações suficientemente robustas para lidar com essas variações. A redução da luminosidade, os reflexos no asfalto molhado e a menor visibilidade dos veículos alteram significativamente as características das imagens.

Impacto operacional: o sistema pode classificar incorretamente vias congestionadas como livres, ou o contrário, comprometendo o planejamento do trânsito e a tomada de decisões pelos operadores.

Abordagem proposta: incluir exemplos rotulados de diferentes condições climáticas e períodos do dia no treinamento. Aplicaria aumentos de dados específicos para iluminação e contraste e avaliaria técnicas de domain adaptation para aproximar as distribuições dos dados de treinamento e produção. A literatura sobre adaptação entre imagens diurnas e noturnas reforça a relevância dessa abordagem.

Conclusão

A maioria dos problemas identificados está relacionada ao dataset de treinamento. Sem uma base de dados diversificada, representativa e com dados de alta qualidade (*padrão-ouro*), torna-se muito difícil desenvolver uma solução robusta e confiável para implantação em produção. Outro problema importante está na avaliação do modelo, pois a acurácia, isoladamente, nem sempre é suficiente para medir seu desempenho. É necessário considerar outras métricas, como precisão, recall e F1-score, além de avaliar a capacidade de generalização do modelo em diferentes cenários de operação.

Link do github com todos os notebooks:
https://github.com/pedrogd96/CNNs_Transformers